

Perbandingan Metode Ekstraksi Fitur Gray Level Co-occurrence Matrix (GLCM), Local Binary Pattern (LBP), dan Feature Fusion pada Klasifikasi Patah Tulang Citra X-ray Menggunakan Support Vector Machine (SVM), Artificial Neural Network (ANN), dan Bayesian Neural Network (BNN)

Nadine Putri Aulia¹, Umi Imro'atus Sholekhah², Cintiya Agustin Nareswari³
¹124031554094@mhs.unesa.ac.id, Universitas Negeri Surabaya, Indonesia
²224031554150@mhs.unesa.ac.id, Universitas Negeri Surabaya, Indonesia
³324031554218@mhs.unesa.ac.id, Universitas Negeri Surabaya, Indonesia

Abstrak

Patah tulang merupakan salah satu cedera yang umum didiagnosis menggunakan citra X-ray. Namun, proses identifikasi secara manual membutuhkan ketelitian tinggi dan berpotensi menimbulkan kesalahan diagnosis. Penelitian ini bertujuan membandingkan performa metode ekstraksi fitur Gray Level Co-occurrence Matrix (GLCM), Local Binary Pattern (LBP), dan Feature Fusion pada klasifikasi citra X-ray patah tulang menggunakan Support Vector Machine (SVM), Artificial Neural Network (ANN), dan Bayesian Neural Network (BNN). Dataset yang digunakan adalah Bone Fracture Detection dari Kaggle yang terdiri atas 2.060 citra setelah proses data cleaning. Tahap preprocessing meliputi resize, grayscale, CLAHE, median blur, dan gaussian blur untuk meningkatkan kualitas citra sebelum ekstraksi fitur dilakukan. Fitur yang dihasilkan kemudian dinormalisasi menggunakan StandardScaler dan digunakan sebagai masukan model klasifikasi. Evaluasi dilakukan menggunakan accuracy, precision, recall, dan F1-score. Hasil penelitian menunjukkan bahwa kombinasi Feature Fusion dan ANN memberikan performa terbaik dengan accuracy 72,29%, precision 75,80%, recall 72,29%, dan F1-score 71,72%. Hasil tersebut menunjukkan bahwa penggabungan fitur GLCM dan LBP mampu menghasilkan representasi tekstur yang lebih lengkap sehingga meningkatkan kemampuan klasifikasi citra X-ray patah tulang.

Kata Kunci: Bone Fracture Detection, X-ray, GLCM, LBP, Feature Fusion, ANN.

Abstract

*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026

Bone fractures are among the most common injuries diagnosed using X-ray images. However, manual identification requires a high level of expertise and is prone to diagnostic errors. This study aims to compare the performance of Gray Level Co-occurrence Matrix (GLCM), Local Binary Pattern (LBP), and Feature Fusion feature extraction methods for bone fracture X-ray image classification using Support Vector Machine (SVM), Artificial Neural Network (ANN), and Bayesian Neural Network (BNN). The dataset used was the Bone Fracture Detection dataset obtained from Kaggle, consisting of 2,060 images after the data cleaning process. The preprocessing stage included image resizing, grayscale conversion, Contrast Limited Adaptive Histogram Equalization (CLAHE), median blur, and Gaussian blur to enhance image quality prior to feature extraction. The extracted features were subsequently normalized using StandardScaler and employed as input for the classification models. Model performance was evaluated using accuracy, precision, recall, and F1-score metrics. The results demonstrated that the combination of Feature Fusion and ANN achieved the best performance, with an accuracy of 72.29%, precision of 75.80%, recall of 72.29%, and F1-score of 71.72%. These findings indicate that combining GLCM and LBP features provides a more comprehensive texture representation, thereby improving the classification performance of bone fracture X-ray images.

Keywords : *Bone Fracture Detection, X-ray, GLCM, LBP, Feature Fusion, ANN.*

1. Pendahuluan

1.1 Latar Belakang

Patah tulang merupakan salah satu cedera yang sering terjadi akibat kecelakaan, olahraga, maupun trauma fisik lainnya. Diagnosis patah tulang umumnya dilakukan menggunakan citra X-ray karena mampu menampilkan struktur tulang secara cepat dan jelas. Namun, proses interpretasi citra X-ray masih dilakukan secara manual oleh tenaga medis sehingga membutuhkan ketelitian tinggi dan waktu analisis yang cukup lama. Selain itu, kesalahan diagnosis masih dapat terjadi terutama pada citra dengan kualitas rendah atau fracture yang sulit terlihat. Oleh karena itu, diperlukan sistem klasifikasi otomatis berbasis machine learning dan computer vision untuk membantu proses identifikasi patah tulang secara lebih cepat dan akurat (Ahmed & Hawezi, 2023; Thinzar, 2019).

Salah satu faktor penting dalam klasifikasi citra medis adalah proses ekstraksi fitur tekstur yang mampu merepresentasikan karakteristik citra secara efektif. Metode Gray Level Co-occurrence Matrix (GLCM) digunakan untuk memperoleh informasi tekstur berdasarkan hubungan antar intensitas piksel, sedangkan Local Binary Pattern (LBP) digunakan untuk memperoleh pola tekstur lokal pada citra (Mall et al., 2019). Sebelum proses ekstraksi fitur dilakukan, citra X-ray terlebih dahulu melalui tahap preprocessing yang meliputi resize image, grayscale conversion, contrast enhancement menggunakan CLAHE, median blur, dan gaussian blur. Tahapan preprocessing bertujuan untuk meningkatkan kualitas citra dan mengurangi noise sehingga proses ekstraksi fitur dapat dilakukan secara lebih optimal (Nia & Shih, 2024; J, 2018). Pada penelitian ini, fitur GLCM dan LBP tidak hanya digunakan secara terpisah, tetapi juga

*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026

digabungkan menggunakan feature fusion untuk memperoleh representasi tekstur yang lebih lengkap melalui kombinasi informasi tekstur global dan lokal dari citra X-ray.

1.2 Pendekatan Pemecahan Masalah

Permasalahan dalam klasifikasi patah tulang pada citra X-ray terletak pada kualitas citra yang bervariasi serta adanya noise yang dapat mempengaruhi proses identifikasi fracture. Untuk mengatasi permasalahan tersebut, penelitian ini menerapkan tahap data cleaning dan preprocessing sebelum proses klasifikasi dilakukan. Tahap preprocessing meliputi resize image, konversi grayscale, peningkatan kontras menggunakan Contrast Limited Adaptive Histogram Equalization (CLAHE), median blur, dan Gaussian blur untuk meningkatkan kualitas citra sehingga informasi yang terkandung pada citra X-ray dapat direpresentasikan dengan lebih baik (Nia & Shih, 2024).

Setelah proses preprocessing, dilakukan ekstraksi fitur menggunakan metode Gray Level Co-occurrence Matrix (GLCM) dan Local Binary Pattern (LBP). Metode GLCM digunakan untuk memperoleh karakteristik tekstur berdasarkan hubungan antar intensitas piksel, sedangkan LBP digunakan untuk memperoleh pola tekstur lokal pada citra. Selain itu, penelitian ini juga menerapkan feature fusion dengan menggabungkan fitur GLCM dan LBP sehingga dihasilkan representasi tekstur yang lebih lengkap untuk proses klasifikasi (Mall et al., 2019).

Tahap selanjutnya adalah proses klasifikasi menggunakan algoritma Support Vector Machine (SVM), Artificial Neural Network (ANN), dan Bayesian Neural Network (BNN). Penggunaan beberapa algoritma klasifikasi bertujuan untuk membandingkan performa masing-masing model terhadap fitur GLCM, fitur LBP, maupun fitur hasil penggabungan keduanya. Hasil klasifikasi kemudian dievaluasi menggunakan accuracy, precision, recall, F1-score, dan confusion matrix untuk menentukan kombinasi metode yang memberikan performa terbaik dalam klasifikasi patah tulang pada citra X-ray.

2. Metodologi

2.1 Eksplorasi Dataset

Penelitian ini menggunakan dataset *Bone Fracture Detection* yang diperoleh dari platform Kaggle. Dataset tersebut berisi citra X-ray tulang manusia yang telah diberi anotasi untuk mendukung pengembangan sistem deteksi dan klasifikasi patah tulang berbasis *computer vision*. Dataset awal dikembangkan untuk kebutuhan *object detection* menggunakan format YOLO, sehingga setiap citra memiliki file anotasi yang berisi informasi kelas objek. Dataset ini dipilih karena menyediakan variasi jenis patah tulang pada area ekstremitas atas sehingga sesuai dengan tujuan penelitian klasifikasi citra medis.

Dataset tersusun dalam tiga subset yaitu data pelatihan (*train*), data validasi (*valid*), dan data pengujian (*test*). Setiap subset terdiri atas folder *images* yang berisi citra X-ray dan folder *labels* yang berisi file anotasi berformat *.txt*. Pada penelitian ini informasi kelas pada file label

*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026

digunakan sebagai target klasifikasi, sedangkan informasi koordinat *bounding box* tidak digunakan karena penelitian berfokus pada klasifikasi berdasarkan fitur tekstur citra. Dataset yang digunakan terdiri atas enam kategori kelas sebagaimana ditunjukkan pada Tabel 1.

Tabel 1. Kelas Dataset

ID Kelas	Nama Kelas
0	Elbow Positive
1	Finger Positive
2	Forearm Fracture
4	Humerus Fracture
5	Shoulder Fracture
6	Wrist Positive

Dataset memiliki beberapa kategori patah tulang yaitu *Elbow Positive*, *Finger Positive*, *Forearm Fracture*, *Humerus Fracture*, *Shoulder Fracture*, dan *Wrist Positive*. Sebelum digunakan pada proses penelitian, dataset terlebih dahulu melalui tahap *data cleaning* yang meliputi penghapusan citra tanpa label (*missing label*), label kosong (*empty label*), data duplikat, serta penghapusan kelas 3 yang tidak digunakan dalam penelitian. Setelah proses pembersihan data selesai dilakukan, seluruh citra diproses melalui tahapan *preprocessing*, ekstraksi fitur GLCM dan LBP, serta klasifikasi menggunakan metode Support Vector Machine (SVM), Artificial Neural Network (ANN), dan Bayesian Neural Network (BNN). Dataset ini dipilih karena memiliki variasi kelas yang cukup beragam sehingga dapat digunakan untuk mengevaluasi performa berbagai metode ekstraksi fitur dan model klasifikasi pada citra X-ray patah tulang.


2.2 Langkah Penelitian

Penelitian ini dilakukan melalui beberapa tahapan yang dimulai dari pengumpulan dataset hingga evaluasi hasil klasifikasi. Tahapan penelitian dirancang untuk membandingkan performa metode ekstraksi fitur Gray Level Co-occurrence Matrix (GLCM), Local Binary Pattern (LBP), dan feature fusion pada klasifikasi patah tulang citra X-ray menggunakan model Support Vector Machine (SVM), Artificial Neural Network (ANN), dan Bayesian Neural Network (BNN).

*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026



Gambar 1. Tahapan Penelitian

1. Data Acquisition

Tahap awal penelitian dilakukan dengan pengumpulan dataset citra X-ray patah tulang yang diperoleh dari Kaggle. Dataset yang digunakan terdiri dari beberapa kategori fracture dan telah dibagi menjadi data train, validation, dan test. Pembagian dataset dilakukan untuk mendukung proses pelatihan, validasi, dan pengujian model klasifikasi (Oyeranmi et al., 2020).

2. Data Cleaning

Tahap data cleaning dilakukan untuk memastikan kualitas dataset sebelum digunakan pada proses penelitian. Proses ini meliputi penghapusan missing labels, empty labels, duplicate images, serta penghapusan class yang tidak digunakan pada penelitian. Tahapan ini bertujuan agar data yang digunakan tetap konsisten dan dapat mengurangi gangguan pada proses pelatihan model.

3. Preprocessing

*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026

Tahap preprocessing bertujuan untuk meningkatkan kualitas citra sebelum dilakukan analisis lebih lanjut. Proses preprocessing meliputi resize image, konversi citra ke grayscale, contrast enhancement menggunakan CLAHE, median blur, dan gaussian blur. Teknik CLAHE digunakan untuk memperjelas detail struktur pada citra medis sehingga tekstur tulang dapat terlihat lebih jelas. Selain itu, proses noise reduction menggunakan median blur dan gaussian blur dilakukan untuk mengurangi gangguan pada citra dan mempertahankan informasi penting.

4. GLCM Feature Extraction

Cabang pertama pada penelitian menggunakan metode Gray Level Co-occurrence Matrix (GLCM). Metode ini digunakan untuk memperoleh karakteristik tekstur berdasarkan hubungan intensitas antar piksel pada citra (Ambika & Mudda, 2020; Mall et al., 2019). Hasil ekstraksi fitur GLCM kemudian direpresentasikan dalam bentuk feature vector yang digunakan sebagai input pada proses klasifikasi.

5. LBP Feature Extraction

Cabang kedua menggunakan metode Local Binary Pattern (LBP). Metode ini digunakan untuk memperoleh pola tekstur lokal dengan membandingkan nilai piksel pusat terhadap piksel di sekitarnya. Hasil ekstraksi fitur kemudian direpresentasikan dalam bentuk feature vector untuk digunakan pada tahap klasifikasi.

6. Feature Fusion

Selain menggunakan fitur secara terpisah, penelitian ini juga menggunakan feature fusion berupa penggabungan fitur GLCM dan LBP. Penggabungan fitur dilakukan untuk memperoleh representasi tekstur yang lebih lengkap melalui kombinasi informasi tekstur global dan lokal dari citra X-ray. Hasil penggabungan fitur kemudian direpresentasikan dalam bentuk fusion vector.

7. Feature Normalization

Tahap feature normalization dilakukan pada seluruh feature vector yaitu GLCM vector, LBP vector, dan fusion vector menggunakan StandardScaler. Normalisasi bertujuan untuk menyamakan rentang nilai fitur sehingga distribusi data menjadi lebih stabil dan membantu meningkatkan performa model selama proses pelatihan.

8. Classification

Tahap selanjutnya adalah proses klasifikasi menggunakan algoritma Support Vector Machine (SVM), Artificial Neural Network (ANN), dan Bayesian Neural Network (BNN). Penggunaan beberapa algoritma klasifikasi bertujuan untuk membandingkan performa masing-masing model terhadap fitur GLCM, fitur LBP, maupun fitur hasil penggabungan keduanya. Pada penelitian ini dilakukan sembilan kombinasi pengujian yaitu GLCM dan SVM, GLCM dan ANN, GLCM dan BNN, LBP dan SVM, LBP dan ANN, LBP dan BNN, Fusion dan SVM, Fusion dan ANN, dan Fusion dan BNN (Alrais & Elfadil, 2020; Pradana et al., 2022).

9. Prediction Result

*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026

Setelah proses pelatihan model selesai dilakukan, setiap model menghasilkan prediction result berupa hasil klasifikasi citra X-ray fracture berdasarkan data pengujian yang digunakan pada penelitian.

10. Model Evaluation

Tahap evaluasi dilakukan untuk mengukur performa model klasifikasi menggunakan beberapa parameter evaluasi seperti accuracy, precision, recall, F1-score, dan confusion matrix. Evaluasi dilakukan pada seluruh kombinasi model untuk mengetahui tingkat performa masing-masing metode klasifikasi.

11. Performance Comparison

Tahap akhir dilakukan dengan membandingkan hasil klasifikasi antara seluruh kombinasi metode yaitu GLCM dan SVM, GLCM dan ANN, GLCM dan BNN, LBP dan SVM, LBP dan ANN, LBP dan BNN, Fusion dan SVM, Fusion dan ANN, dan Fusion dan BNN berdasarkan hasil evaluasi model. Hasil perbandingan digunakan untuk menentukan kombinasi metode yang memberikan performa terbaik pada klasifikasi patah tulang citra X-ray.

2.3 Data Acquisition

Tahap data acquisition dilakukan dengan mengumpulkan dataset citra X-ray patah tulang yang diperoleh dari platform Kaggle. Dataset yang digunakan terdiri atas citra X-ray berbagai kategori fracture yang telah dibagi ke dalam data pelatihan (training set), data validasi (validation set), dan data pengujian (test set). Data pelatihan digunakan untuk membangun model klasifikasi, data validasi digunakan untuk mengevaluasi performa model selama proses pelatihan, sedangkan data pengujian digunakan untuk mengukur performa akhir model terhadap data yang belum pernah digunakan sebelumnya. Seluruh data citra dan label yang diperoleh kemudian diperiksa untuk memastikan kesesuaian data sebelum digunakan pada tahap penelitian berikutnya.

2.4 Data Cleaning

Tahap data cleaning dilakukan untuk memastikan kualitas data yang digunakan pada penelitian. Proses ini bertujuan untuk menghilangkan data yang tidak valid sehingga dapat mengurangi kesalahan selama proses ekstraksi fitur dan pelatihan model klasifikasi. Kualitas dataset merupakan faktor penting yang dapat memengaruhi performa model klasifikasi citra medis sehingga data perlu diverifikasi sebelum digunakan pada proses pembelajaran model.

2.4.1 Remove Missing Labels

Tahap pertama dilakukan dengan memeriksa kesesuaian antara file citra dan file label yang tersedia pada dataset. Setiap citra seharusnya memiliki file anotasi berformat *.txt* yang berisi informasi kelas objek. Apabila suatu citra tidak memiliki file label yang sesuai, maka citra tersebut tidak dapat digunakan karena tidak memiliki informasi target kelas yang diperlukan dalam proses klasifikasi.

Pada penelitian ini dilakukan pengecekan keberadaan file label untuk setiap citra

*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026

menggunakan nama file yang sama antara citra dan label. Citra yang tidak memiliki pasangan file label dihapus dari dataset sehingga hanya data yang memiliki informasi kelas yang valid yang digunakan pada tahap selanjutnya.

2.4.2 Remove Empty Labels

Selain keberadaan file label, isi dari file label juga diperiksa untuk memastikan bahwa informasi kelas tersedia dengan benar. Beberapa file label dapat ditemukan dalam kondisi kosong sehingga tidak mengandung informasi kelas apa pun.

File label yang kosong tidak dapat digunakan untuk proses pembelajaran model karena tidak memiliki target klasifikasi yang jelas. Oleh karena itu, seluruh citra yang memiliki file label kosong dihapus dari dataset. Proses ini dilakukan untuk menjaga konsistensi data dan mencegah kesalahan pada tahap ekstraksi fitur maupun pelatihan model.

2.4.3 Remove Duplicate Images

Tahap berikutnya adalah penghapusan data duplikat. Data duplikat dapat menyebabkan bias pada proses pelatihan model karena citra yang sama dapat muncul lebih dari satu kali sehingga meningkatkan peluang model menghafal data tertentu. Kondisi tersebut dapat memengaruhi kemampuan model dalam melakukan generalisasi terhadap data baru dan menyebabkan hasil evaluasi menjadi kurang representatif.

Identifikasi data duplikat dilakukan berdasarkan alamat file citra (*image path*) yang tersimpan pada dataset. Apabila ditemukan data dengan informasi citra yang sama, maka hanya satu data yang dipertahankan sedangkan data lainnya dihapus. Proses ini dilakukan untuk memastikan bahwa setiap citra hanya direpresentasikan satu kali pada dataset penelitian.

2.4.4 Remove Class 3

Berdasarkan hasil eksplorasi dataset, dilakukan pemeriksaan terhadap keberadaan kelas dengan ID 3 pada dataset. Hasil pemeriksaan menunjukkan bahwa tidak ditemukan data yang termasuk ke dalam kelas tersebut sehingga tidak dilakukan proses penghapusan data pada tahap ini.

Penghapusan kelas tersebut bertujuan untuk menyesuaikan dataset dengan kebutuhan penelitian sehingga kelas yang digunakan hanya terdiri atas enam kategori, yaitu *Elbow Positive*, *Finger Positive*, *Forearm Fracture*, *Humerus Fracture*, *Shoulder Fracture*, dan *Wrist Positive*. Dengan demikian, proses klasifikasi dilakukan pada kelas yang sesuai dengan ruang lingkup penelitian.

2.5 Preprocessing

Tahap preprocessing dilakukan untuk meningkatkan kualitas citra X-ray sebelum proses ekstraksi fitur dilakukan. Tahapan ini bertujuan untuk memperjelas struktur tulang, mengurangi

*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026

noise pada citra, serta menghasilkan citra yang lebih konsisten sehingga proses ekstraksi fitur dapat berjalan lebih optimal. Pada penelitian ini, preprocessing dilakukan melalui beberapa tahapan yaitu resize image, grayscale conversion, contrast enhancement menggunakan CLAHE, median blur, dan gaussian blur.

2.5.1 Resize Image

Tahap pertama pada preprocessing adalah resize image dengan ukuran 224×224 piksel. Proses resize dilakukan untuk menyeragamkan ukuran seluruh citra sehingga memudahkan proses pengolahan data dan mengurangi kompleksitas komputasi selama proses ekstraksi fitur dan klasifikasi.

2.5.2 Grayscale Conversion

Setelah proses resize, citra dikonversi menjadi grayscale menggunakan OpenCV. Konversi grayscale dilakukan untuk mengubah citra RGB menjadi citra dengan satu tingkat intensitas sehingga proses analisis tekstur menjadi lebih efektif. Penggunaan grayscale juga membantu mengurangi kompleksitas data tanpa menghilangkan informasi penting pada struktur tulang.

2.5.3 CLAHE Enhancement

Tahap selanjutnya adalah peningkatan kontras menggunakan metode Contrast Limited Adaptive Histogram Equalization (CLAHE). Metode ini digunakan untuk memperjelas detail struktur tulang pada citra X-ray sehingga area fracture dapat terlihat lebih jelas. Pada penelitian ini digunakan parameter clipLimit = 2.0 dan tileGridSize = (8,8). Penggunaan CLAHE dinilai efektif dalam meningkatkan kualitas citra medis terutama pada citra dengan kontras rendah.

2.5.4 Median Blur

Setelah peningkatan kontras, dilakukan proses median blur dengan kernel size 3×3 untuk mengurangi noise berupa bintik-bintik kecil pada citra tanpa menghilangkan tepi objek secara signifikan. Median blur membantu mempertahankan detail penting pada struktur tulang sehingga informasi tekstur tetap terjaga.

2.5.5 Gaussian Blur

Tahap terakhir preprocessing adalah gaussian blur menggunakan kernel size 3×3 . Gaussian blur digunakan untuk menghaluskan citra dan mengurangi noise tambahan yang masih tersisa setelah proses median blur. Hasil preprocessing akhir berupa citra grayscale dengan kualitas yang lebih baik dan siap digunakan pada tahap ekstraksi fitur GLCM dan LBP.

2.6 Feature Extraction

Tahap feature extraction dilakukan setelah proses preprocessing selesai untuk memperoleh karakteristik tekstur dari citra X-ray. Pada penelitian ini digunakan dua metode ekstraksi fitur, yaitu Gray Level Co-occurrence Matrix (GLCM) dan Local Binary Pattern (LBP). Selain itu, dilakukan pula feature fusion dengan menggabungkan fitur GLCM dan LBP untuk memperoleh representasi tekstur yang lebih lengkap sebelum digunakan pada proses klasifikasi.

*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026

2.6.1 GLCM Feature Extraction

Gray Level Co-occurrence Matrix (GLCM) digunakan untuk mengekstraksi karakteristik tekstur berdasarkan hubungan antar intensitas piksel pada citra. Pada penelitian ini, fitur yang dihasilkan meliputi contrast, dissimilarity, homogeneity, energy, correlation, dan Angular Second Moment (ASM) yang dihitung pada beberapa kombinasi jarak dan sudut. Hasil ekstraksi kemudian direpresentasikan dalam bentuk feature vector yang digunakan sebagai masukan pada proses klasifikasi.

2.6.2 LBP Feature Extraction

Local Binary Pattern (LBP) digunakan untuk memperoleh informasi tekstur lokal dengan membandingkan nilai intensitas piksel pusat terhadap piksel di sekitarnya. Setiap piksel direpresentasikan menjadi pola biner yang kemudian disusun menjadi histogram fitur. Hasil ekstraksi LBP digunakan sebagai feature vector yang merepresentasikan karakteristik tekstur lokal dari citra X-ray dan selanjutnya digunakan pada tahap klasifikasi.

2.6.3 Feature Fusion

Feature fusion dilakukan dengan menggabungkan feature vector hasil ekstraksi GLCM dan LBP menggunakan metode concatenation. Penggabungan fitur bertujuan untuk mengombinasikan informasi tekstur global dan lokal sehingga menghasilkan representasi data yang lebih lengkap dibandingkan penggunaan fitur tunggal. Pendekatan penggabungan fitur telah digunakan pada klasifikasi citra medis untuk meningkatkan kualitas informasi yang digunakan pada proses klasifikasi (Alibabaei et al., 2025).

2.7 Feature Normalization

Tahap feature normalization dilakukan setelah proses ekstraksi fitur GLCM, LBP, dan feature fusion selesai dilakukan. Normalisasi bertujuan untuk menyamakan rentang nilai fitur sehingga distribusi data menjadi lebih stabil sebelum digunakan pada proses klasifikasi. Pada penelitian ini, normalisasi dilakukan menggunakan metode StandardScaler dari library Scikit-learn yang mengubah distribusi data agar memiliki nilai rata-rata mendekati 0 dan standar deviasi sebesar 1.

Proses normalisasi dilakukan secara terpisah pada feature vector GLCM, feature vector LBP, dan fusion vector. Data training digunakan pada proses fit_transform, sedangkan data validation dan testing menggunakan transform berdasarkan parameter dari data training untuk menghindari data leakage. Hasil normalisasi kemudian digunakan sebagai input pada model klasifikasi Support Vector Machine (SVM), Artificial Neural Network (ANN), dan Bayesian Neural Network (BNN) (Pradana et al., 2022).

2.8 Label Encoding dan Class Weight

Sebelum proses klasifikasi dilakukan, label kelas pada dataset terlebih dahulu dikonversi ke

*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026

dalam bentuk numerik menggunakan metode *Label Encoding*. Tahap ini bertujuan agar setiap kelas dapat direpresentasikan dalam bentuk yang dapat diproses oleh algoritma klasifikasi. Selain itu, penelitian ini juga menerapkan *class weight* untuk mengatasi ketidakseimbangan jumlah data pada setiap kelas. Pemberian bobot dilakukan berdasarkan distribusi data sehingga kelas dengan jumlah sampel yang lebih sedikit memperoleh bobot yang lebih besar dibandingkan kelas mayoritas. Dengan demikian, model dapat mempelajari seluruh kelas secara lebih seimbang dan mengurangi kemungkinan terjadinya bias terhadap kelas yang memiliki jumlah data lebih banyak selama proses pelatihan.

2.9 Model Klasifikasi

2.9.1 Support Vector Machine (SVM)

Support Vector Machine (SVM) merupakan algoritma machine learning yang digunakan untuk melakukan klasifikasi dengan mencari hyperplane optimal yang mampu memisahkan data dari kelas yang berbeda. SVM memiliki kemampuan yang baik dalam menangani data berdimensi tinggi dan banyak digunakan pada berbagai penelitian klasifikasi citra medis karena mampu menghasilkan performa yang stabil serta tingkat akurasi yang tinggi.

Pada penelitian ini, Support Vector Machine (SVM) digunakan sebagai model klasifikasi untuk mengenali kategori patah tulang berdasarkan fitur hasil ekstraksi GLCM, LBP, dan Feature Fusion. Pemilihan SVM didasarkan pada kemampuannya dalam melakukan klasifikasi data berdimensi tinggi dan menghasilkan performa yang baik pada berbagai kasus klasifikasi citra medis.

2.9.2 Artificial Neural Network (ANN)

Artificial Neural Network (ANN) merupakan salah satu metode deep learning yang digunakan pada penelitian ini untuk proses klasifikasi citra X-ray patah tulang. ANN dipilih karena mampu mempelajari pola non-linear dan hubungan kompleks pada data hasil ekstraksi fitur tekstur citra medis. Pada penelitian ini, ANN digunakan untuk mengklasifikasikan fitur hasil ekstraksi GLCM, LBP, dan feature fusion ke dalam beberapa kelas fracture. Model ANN yang digunakan terdiri dari input layer, hidden layer, dan output layer dengan fungsi aktivasi ReLU pada hidden layer dan softmax pada output layer. Selain itu, digunakan Batch Normalization dan Dropout untuk membantu meningkatkan stabilitas pelatihan model dan mengurangi risiko overfitting. Proses pelatihan dilakukan menggunakan optimizer Adam dan loss function categorical crossentropy dengan penerapan Early Stopping untuk menghentikan pelatihan secara otomatis apabila performa model tidak mengalami peningkatan dalam beberapa epoch.

2.9.3 Bayesian Neural Network (BNN)

Bayesian Neural Network (BNN) merupakan salah satu model klasifikasi yang digunakan pada penelitian ini. BNN menerapkan pendekatan probabilistik pada parameter jaringan saraf sehingga setiap bobot direpresentasikan dalam bentuk distribusi probabilitas. Pendekatan tersebut memungkinkan model untuk memperhitungkan ketidakpastian selama proses prediksi.

*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026

Penggunaan model machine learning pada klasifikasi patah tulang telah banyak diterapkan untuk membantu meningkatkan akurasi identifikasi fracture pada citra X-ray. Pada penelitian ini, BNN digunakan untuk mengklasifikasikan citra patah tulang berdasarkan fitur hasil ekstraksi GLCM, LBP, dan feature fusion. Model BNN dibangun menggunakan DenseFlipout Layer yang memungkinkan setiap bobot direpresentasikan dalam bentuk distribusi probabilitas sehingga dapat memperkirakan ketidakpastian prediksi selama proses klasifikasi. Hasil klasifikasi kemudian dibandingkan dengan model SVM dan ANN untuk mengevaluasi performa yang dihasilkan.

2.10 Model Evaluasi

Tahap evaluasi dilakukan untuk mengukur kemampuan model dalam mengklasifikasikan citra X-ray patah tulang. Evaluasi dilakukan menggunakan beberapa metrik, yaitu accuracy, precision, recall, F1-score, dan confusion matrix. Penggunaan beberapa metrik evaluasi bertujuan untuk memberikan gambaran yang lebih komprehensif mengenai performa model klasifikasi pada setiap kelas yang diuji (Oyeranmi et al., 2020).

2.10.1 Accuracy

Accuracy digunakan untuk mengukur tingkat ketepatan model dalam melakukan klasifikasi. Metrik ini menunjukkan persentase data yang berhasil diprediksi dengan benar dibandingkan dengan seluruh data pengujian. Semakin tinggi nilai accuracy, semakin baik kemampuan model dalam melakukan klasifikasi.

2.10.2 Precision

Precision digunakan untuk mengukur ketepatan hasil prediksi yang diberikan oleh model. Metrik ini menunjukkan seberapa banyak prediksi pada suatu kelas yang benar-benar sesuai dengan kelas sebenarnya. Nilai precision yang tinggi menunjukkan bahwa model mampu meminimalkan kesalahan prediksi antar kelas.

2.10.3 Recall

Recall digunakan untuk mengukur kemampuan model dalam mengenali seluruh data yang termasuk ke dalam suatu kelas tertentu. Nilai recall yang tinggi menunjukkan bahwa model mampu mendeteksi sebagian besar sampel yang seharusnya masuk ke dalam kelas tersebut.

2.10.4 F1-Score

F1-score merupakan metrik yang menggabungkan precision dan recall untuk memberikan ukuran performa yang lebih seimbang. Metrik ini banyak digunakan pada kasus klasifikasi dengan distribusi data yang tidak merata karena dapat menunjukkan keseimbangan antara ketepatan dan kemampuan deteksi model.

2.10.5 Confusion Matrix

Confusion matrix digunakan untuk menganalisis hasil klasifikasi secara lebih rinci. Melalui confusion matrix dapat diketahui jumlah data yang berhasil maupun gagal diklasifikasikan pada masing-masing kelas. Informasi tersebut membantu dalam mengidentifikasi pola kesalahan prediksi yang dilakukan oleh model sehingga performa

*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026

klasifikasi dapat dievaluasi secara lebih mendalam .

2.11 Perbandingan Model

Tahap performance comparison dilakukan untuk membandingkan performa seluruh kombinasi metode ekstraksi fitur dan model klasifikasi yang digunakan pada penelitian. Perbandingan dilakukan pada kombinasi GLCM dan SVM, GLCM dan ANN, GLCM dan BNN, LBP dan SVM, LBP dan ANN, LBP dan BNN, Fusion dan SVM, Fusion dan ANN, dan Fusion dan BNN. Tujuan dari tahap ini adalah untuk mengetahui kombinasi metode yang memberikan performa terbaik pada klasifikasi citra X-ray patah tulang.

17 Proses perbandingan dilakukan berdasarkan hasil evaluasi model menggunakan accuracy, precision, recall, F1-score, dan confusion matrix. Hasil evaluasi kemudian disajikan dalam bentuk tabel dan grafik perbandingan untuk mempermudah proses analisis performa masing-masing model. Kombinasi metode dengan nilai evaluasi terbaik dipilih sebagai model terbaik pada penelitian ini.

3. Hasil Analisis

3.1 Hasil Pengumpulan Dataset

19 Dataset yang digunakan dalam penelitian ini merupakan dataset citra X-ray patah tulang yang diperoleh dari Kaggle. Dataset tersedia dalam tiga subset, yaitu data pelatihan (*training set*), data validasi (*validation set*), dan data pengujian (*test set*). Pembagian dataset ini bertujuan untuk mendukung proses pelatihan, validasi, dan pengujian model klasifikasi. Distribusi dataset awal yang digunakan dalam penelitian ditunjukkan pada Tabel 2.

Tabel 2. Distribusi Dataset Awal

Dataset	Jumlah Citra
Training	3631
Validation	348
Testing	169
Total	4148

Berdasarkan Tabel 2. total dataset awal yang berhasil dikumpulkan berjumlah 4.148 citra. Dataset tersebut selanjutnya digunakan pada tahap *data cleaning* untuk menghilangkan data yang tidak memenuhi kriteria penelitian sebelum dilakukan proses ekstraksi fitur dan klasifikasi

3.2 Hasil Data Cleaning

Tahap data cleaning dilakukan untuk memastikan bahwa data yang digunakan pada penelitian memiliki kualitas yang baik dan layak digunakan pada proses klasifikasi. Dataset awal terdiri atas 4.148 citra X-ray yang terbagi menjadi 3.631 data train, 348 data validation, dan 169

*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026

data test. Hasil pemeriksaan menunjukkan bahwa seluruh citra memiliki pasangan file label sehingga tidak ditemukan kasus missing labels pada dataset.

Pemeriksaan selanjutnya dilakukan terhadap isi file label untuk mengidentifikasi label kosong. Hasilnya menunjukkan bahwa terdapat 2.088 citra yang memiliki label kosong, terdiri atas 1.827 data train, 175 data validation, dan 86 data test. Selain itu, tidak ditemukan data pada kelas 3 maupun citra duplikat sehingga tidak ada data yang dihapus pada kedua tahap tersebut. Berdasarkan hasil data cleaning, sebanyak 2.088 citra atau sekitar 50,34% dari total dataset awal dieliminasi karena memiliki label kosong (empty label). Meskipun jumlah data berkurang secara signifikan, proses ini diperlukan untuk memastikan bahwa setiap citra memiliki target klasifikasi yang valid sehingga dapat digunakan dalam proses pelatihan dan evaluasi model secara tepat. Ringkasan hasil data cleaning ditunjukkan pada Tabel 3.

Tabel 3. Hasil Data Cleaning

Dataset	Total Awal	Missing Label	Empty Label	Class 3	Total Akhir
Train	3.631	0	1.827	0	1.804
Validation	348	0	175	0	173
Test	169	0	86	0	83
Total	4.148	0	2.088	0	2.060

Berdasarkan hasil eksplorasi dataset, tidak ditemukan data yang termasuk ke dalam kelas 3 sehingga tidak ada data yang dihapus pada tahap remove class 3. Selain itu, proses pemeriksaan data duplikat berdasarkan image path menunjukkan bahwa tidak terdapat citra yang muncul lebih dari satu kali pada dataset. Jumlah data sebelum dan sesudah proses duplicate removal tetap sama yaitu sebanyak 2.060 citra. Hasil pemeriksaan data duplikat ditunjukkan pada Tabel 4.

Tabel 4. Hasil Pemeriksaan Data Duplikat

Keterangan	Jumlah Data
Sebelum Pemeriksaan	2.060
Sesudah Pemeriksaan	2.060
Data Duplikat Dihapus	0

Setelah seluruh tahapan data cleaning selesai dilakukan, diperoleh dataset akhir sebanyak 2.060 citra yang terdiri atas 1.804 data pelatihan, 173 data validasi, dan 83 data pengujian. Dataset hasil pembersihan ini selanjutnya digunakan pada tahap preprocessing, ekstraksi fitur tekstur menggunakan metode GLCM dan LBP, serta proses klasifikasi menggunakan model SVM, ANN, dan BNN.

3.3 Hasil Preprocessing

Tahap preprocessing dilakukan untuk meningkatkan kualitas citra X-ray sebelum proses

*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026

ekstraksi fitur dilakukan. Hasil preprocessing ditunjukkan pada Gambar yang terdiri dari tahapan resize, grayscale, CLAHE, median blur, dan gaussian blur.



Gambar 2. Hasil Preprocessing

Pada tahap resize, seluruh citra diubah menjadi ukuran 224×224 piksel untuk menyeragamkan dimensi data sebelum proses pengolahan dilakukan. Hasil resize menunjukkan bahwa meskipun ukuran citra diperkecil, struktur utama tulang dan area fracture masih dapat terlihat dengan cukup jelas sehingga informasi penting pada citra tetap dipertahankan.

Tahap grayscale menghasilkan citra dengan satu tingkat intensitas sehingga detail tekstur tulang menjadi lebih fokus dibandingkan citra sebelumnya. Setelah itu dilakukan CLAHE untuk meningkatkan kontras citra. Hasil CLAHE menunjukkan bahwa area tulang dan garis fracture terlihat lebih jelas dibandingkan citra grayscale karena perbedaan intensitas pada struktur tulang menjadi lebih tegas. Peningkatan kontras tersebut membantu memperjelas detail tekstur yang akan digunakan pada proses ekstraksi fitur.

Tahap median blur menghasilkan citra yang lebih halus dengan berkurangnya noise berupa bintik-bintik kecil pada citra X-ray tanpa menghilangkan detail utama pada struktur tulang. Selanjutnya gaussian blur digunakan untuk menghaluskan citra secara lebih merata sehingga tampilan citra menjadi lebih stabil dan tidak terlalu tajam. Hasil akhir preprocessing menunjukkan bahwa kualitas citra menjadi lebih baik dengan kontras yang meningkat dan noise yang lebih rendah sehingga proses ekstraksi fitur GLCM dan LBP dapat dilakukan secara lebih optimal.


3.4 Hasil Feature Extraction

Pada penelitian ini dilakukan ekstraksi fitur menggunakan metode Gray Level Co-occurrence Matrix (GLCM) dan Local Binary Pattern (LBP). GLCM digunakan untuk memperoleh karakteristik tekstur global citra, sedangkan LBP digunakan untuk memperoleh karakteristik tekstur lokal. Selanjutnya fitur hasil ekstraksi GLCM dan LBP digabungkan menggunakan metode feature fusion untuk menghasilkan representasi fitur yang lebih lengkap.

*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026



Gambar 3. Visualisasi Hasil Ekstraksi Fitur GLCM dan LBP

Berdasarkan Gambar 3, citra hasil preprocessing berhasil mempertahankan struktur anatomi tulang yang menjadi objek utama pada citra X-ray. Pada visualisasi GLCM Matrix terlihat dominasi warna gelap yang menunjukkan bahwa sebagian besar nilai ko-occurrence antar tingkat keabuan memiliki probabilitas yang sangat kecil. Nilai yang signifikan hanya terkonsentrasi pada beberapa pasangan tingkat keabuan tertentu sehingga distribusi matriks tampak tidak merata. Kondisi tersebut mengindikasikan adanya pola tekstur khas pada citra tulang yang dapat direpresentasikan melalui fitur GLCM seperti contrast, dissimilarity, homogeneity, energy, correlation, dan ASM. Sementara itu, hasil transformasi LBP menunjukkan pola tekstur lokal yang lebih jelas pada area tulang melalui perubahan intensitas piksel yang menggambarkan perbedaan karakteristik permukaan citra. Kombinasi informasi tekstur global dari GLCM dan tekstur lokal dari LBP selanjutnya digunakan sebagai representasi fitur untuk proses klasifikasi patah tulang.

3.4.1 Hasil Ekstraksi Fitur GLCM

Ekstraksi fitur GLCM dilakukan pada seluruh citra hasil preprocessing untuk memperoleh karakteristik tekstur citra X-ray. Proses ekstraksi menghasilkan fitur tekstur berupa *contrast*, *dissimilarity*, *homogeneity*, *energy*, *correlation*, dan *Angular Second Moment (ASM)* yang dihitung berdasarkan hubungan intensitas antar piksel pada berbagai kombinasi jarak dan sudut. Hasil ekstraksi kemudian direpresentasikan dalam bentuk *feature vector* yang digunakan sebagai masukan pada tahap klasifikasi.

Tabel 5. Hasil Ekstraksi Fitur GLCM

Keterangan	Nilai
Jumlah Citra	2060
Jumlah Fitur Percitra	72
Ukuran Matriks Fitur	2060 x 72

Berdasarkan Tabel 5., proses ekstraksi fitur GLCM berhasil menghasilkan 72 fitur tekstur

*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026

untuk setiap citra yang digunakan dalam penelitian. Jumlah fitur tersebut diperoleh dari kombinasi enam properti tekstur yaitu contrast, dissimilarity, homogeneity, energy, correlation, dan ASM yang dihitung pada beberapa kombinasi jarak dan sudut. Fitur-fitur tersebut selanjutnya digunakan sebagai representasi karakteristik citra X-ray dan menjadi masukan pada model klasifikasi SVM, ANN, dan BNN untuk mengevaluasi performa klasifikasi berdasarkan fitur GLCM.

3.4.2 Hasil Ekstraksi Fitur LBP

Ekstraksi fitur Local Binary Pattern (LBP) dilakukan pada seluruh citra hasil preprocessing untuk memperoleh karakteristik tekstur lokal dari citra X-ray. Metode LBP bekerja dengan membandingkan nilai intensitas piksel pusat terhadap piksel di sekitarnya sehingga menghasilkan representasi pola tekstur yang relatif sederhana namun efektif dalam membedakan karakteristik citra. Hasil ekstraksi kemudian direpresentasikan dalam bentuk histogram fitur yang digunakan sebagai masukan pada tahap klasifikasi.

Berdasarkan proses ekstraksi yang dilakukan terhadap seluruh dataset, diperoleh matriks fitur LBP yang merepresentasikan setiap citra dalam bentuk vektor fitur. Ringkasan hasil ekstraksi fitur LBP ditunjukkan pada Tabel 6.

Tabel 6. Hasil Ekstraksi Fitur LBP

Keterangan	Nilai
Jumlah Citra	2.060
Jumlah Fitur Per Citra	18
Ukuran Matriks Fitur	2.060 x 18

Hasil pada Tabel 6. menunjukkan bahwa sebanyak 2060 citra berhasil diekstraksi dan setiap citra direpresentasikan oleh 18 fitur LBP. Jumlah fitur tersebut diperoleh dari penggunaan parameter radius sebesar 2 dan jumlah titik tetangga (*n_points*) sebanyak 16 pada proses ekstraksi. Seluruh fitur yang dihasilkan selanjutnya digunakan sebagai data masukan pada model klasifikasi SVM, ANN, dan BNN untuk mengevaluasi kemampuan fitur tekstur lokal dalam membedakan kategori patah tulang pada citra X-ray.

3.4.3 Hasil Ekstraksi Fitur Fusion

Ekstraksi Fitur dilakukan pada seluruh citra hasil preprocessing dengan menggabungkan feature vector hasil ekstraksi GLCM dan LBP untuk memperoleh representasi tekstur yang lebih lengkap pada citra X-ray. Hasil feature fusion kemudian digunakan sebagai masukan pada tahap klasifikasi menggunakan model SVM, ANN, dan BNN.

Tabel 7. Hasil Ekstraksi Fitur Fusion

*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026

Keterangan	Nilai
Jumlah Citra	2060
Jumlah Fitur per Citra	90
Ukuran Matriks Fitur	2060 x 90

Berdasarkan hasil feature fusion pada Tabel 7. proses penggabungan fitur berhasil menghasilkan feature vector baru berukuran (2060, 90). Jumlah fitur tersebut diperoleh dari penggabungan 72 fitur GLCM dan 18 fitur LBP menggunakan metode concatenation sehingga menghasilkan representasi tekstur yang lebih lengkap. Hasil tersebut menunjukkan bahwa feature fusion mampu menghasilkan representasi data dengan jumlah fitur yang lebih banyak sehingga diharapkan dapat membantu model klasifikasi dalam mempelajari karakteristik fracture pada citra X-ray secara lebih optimal.

3.5 Hasil Normalisasi dan Persiapan Data

Setelah proses ekstraksi fitur selesai dilakukan, data selanjutnya dinormalisasi menggunakan metode *StandardScaler* untuk menyamakan rentang nilai pada setiap fitur. Normalisasi diterapkan pada fitur GLCM, LBP, dan *Feature Fusion* sehingga data yang digunakan pada tahap klasifikasi memiliki skala yang lebih seragam. Selain itu, dilakukan proses *Label Encoding* untuk mengubah label kelas ke dalam bentuk numerik agar dapat diproses oleh model klasifikasi. Hasil proses *Label Encoding* menunjukkan bahwa dataset terdiri atas enam kelas yang digunakan dalam penelitian. Untuk mengatasi ketidakseimbangan jumlah data pada setiap kelas, diterapkan *class weight* yang dihitung berdasarkan distribusi data pelatihan. Nilai *class weight* yang diperoleh ditunjukkan pada Tabel 8.

Tabel 8. Nilai Class Weight

Kelas	Class Weight
Elbow Positive	0,9826
Finger Positive	0,6944
Forearm Fracture	1,0624
Humerus Fracture	1,0056
Shoulder Fracture	0,9545
Wrist Positive	1,7897

Berdasarkan Tabel 8. kelas *Wrist Positive* memiliki nilai *class weight* tertinggi sebesar 1,7897 yang menunjukkan bahwa jumlah data pada kelas tersebut lebih sedikit dibandingkan kelas lainnya. Sebaliknya, kelas *Finger Positive* memiliki nilai *class weight* terendah sebesar 0,6944 karena memiliki jumlah data yang relatif lebih banyak. Penerapan *class weight* bertujuan untuk membantu model mempelajari setiap kelas secara lebih seimbang dan mengurangi bias

*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026

terhadap kelas mayoritas selama proses pelatihan.

3.6 Optimasi Parameter Model

Sebelum menentukan konfigurasi akhir yang digunakan dalam penelitian, dilakukan beberapa percobaan parameter pada tahap preprocessing, ekstraksi fitur, dan klasifikasi. Tujuan dari proses optimasi ini adalah untuk memperoleh kombinasi parameter yang mampu menghasilkan performa klasifikasi terbaik pada citra X-ray patah tulang. Beberapa konfigurasi diuji dengan memodifikasi parameter CLAHE, GLCM, LBP, serta penggunaan teknik reduksi dimensi dan penambahan fitur. Hasil dari setiap percobaan kemudian dibandingkan berdasarkan nilai accuracy, precision, recall, dan F1-score untuk menentukan konfigurasi yang paling optimal.

3.6.1 Percobaan Pertama

Percobaan pertama dilakukan dengan meningkatkan kontras citra menggunakan CLAHE dengan nilai clipLimit sebesar 3,0 serta menambahkan proses sharpening setelah Gaussian Blur. Pada tahap ekstraksi fitur, digunakan parameter GLCM dengan kombinasi jarak (distances) [1, 2, 4, 8] dan parameter LBP dengan radius sebesar 3. Selain itu, pada fitur hasil penggabungan (Feature Fusion) diterapkan Principal Component Analysis (PCA) dengan tingkat variasi data sebesar 95% untuk mengurangi dimensi fitur.

Hasil pengujian menunjukkan bahwa peningkatan kontras yang terlalu tinggi menyebabkan beberapa area pada citra menjadi terlalu terang sehingga detail tekstur tertentu kurang terrepresentasikan dengan baik. Penggunaan PCA juga menyebabkan sebagian informasi tekstur hilang sehingga performa klasifikasi belum menunjukkan peningkatan yang signifikan dibandingkan konfigurasi dasar.

Tabel 9. Hasil Percobaan Pertama

Parameter	Nilai
CLAHE clipLimit	3.0
Sharpening	Ya
GLCM distances	[1,2,4,8]
LBP radius	3
PCA	95%

3.6.2 Percobaan Kedua

*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026

Percobaan kedua dilakukan dengan memperluas cakupan informasi tekstur menggunakan parameter GLCM distances [1, 2, 4, 8] dan meningkatkan parameter LBP menjadi radius 4 dengan jumlah titik tetangga (n_points) sebesar 128. Selain itu, ditambahkan beberapa fitur statistik sebagai pelengkap representasi tekstur citra.

Hasil pengujian menunjukkan bahwa jumlah fitur yang dihasilkan menjadi jauh lebih besar dibandingkan percobaan sebelumnya. Meskipun informasi yang diperoleh lebih lengkap, peningkatan dimensi fitur menyebabkan proses pelatihan model menjadi lebih kompleks dan tidak menghasilkan peningkatan performa yang konsisten pada seluruh model klasifikasi. Beberapa model bahkan menunjukkan indikasi overfitting karena jumlah fitur yang terlalu besar dibandingkan jumlah data yang tersedia.

Tabel 10. Hasil Percobaan Kedua

Parameter	Nilai
GLCM distances	[1,2,4,8]
LBP radius	4
LBP n_points	128
Fitur Statistik Tambahan	Ya

3.6.3 Pemilihan Konfigurasi Akhir

Berdasarkan hasil beberapa percobaan yang telah dilakukan, dipilih konfigurasi akhir yang memberikan performa paling baik dan stabil pada proses klasifikasi. Konfigurasi tersebut terdiri atas ukuran citra 224×224 piksel, CLAHE dengan clipLimit 2,0, Median Blur 3×3 , Gaussian Blur 3×3 , parameter GLCM distances [1, 2, 3], serta parameter LBP radius 2 dengan n_points 16. Pada tahap Feature Fusion, fitur GLCM dan LBP digabungkan menggunakan metode concatenation tanpa penerapan PCA.

Tabel 11. Konfigurasi Akhir Penelitian

Tahap	Parameter
Resize Image	224 x 224
CLAHE	clipLimit = 2.0
Median Blur	3 x 3
Gaussian Blur	3 x 3

*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026

GLCM distances	[1,2,3]
LBP radius	2
LBP n_points	16
Feature Fusion	Concatenation tanpa PCA

Konfigurasi ini dipilih karena mampu menghasilkan representasi tekstur yang lebih seimbang antara informasi global dan lokal serta memberikan performa klasifikasi terbaik pada sebagian besar model yang diuji. Hasil pengujian menunjukkan bahwa kombinasi konfigurasi tersebut menghasilkan nilai accuracy, precision, recall, dan F1-score yang lebih tinggi dibandingkan konfigurasi percobaan lainnya. Oleh karena itu, seluruh hasil klasifikasi yang disajikan pada bagian selanjutnya menggunakan konfigurasi akhir tersebut.

3.7 Hasil Pelatihan dan Pengujian Model

Pada tahap ini dilakukan pelatihan dan pengujian model klasifikasi menggunakan metode Support Vector Machine (SVM), Artificial Neural Network (ANN), dan Bayesian Neural Network (BNN) pada fitur GLCM, LBP, serta Feature Fusion (GLCM dan LBP). Kinerja setiap model dievaluasi menggunakan metrik accuracy, precision, recall, dan F1-score untuk mengetahui kombinasi fitur dan model yang memberikan performa terbaik dalam klasifikasi citra X-ray patah tulang

3.7.1 Hasil GLCM dan SVM

Pengujian pertama dilakukan menggunakan kombinasi fitur Gray Level Co-occurrence Matrix (GLCM) dan algoritma Support Vector Machine (SVM). Pada tahap ini, fitur tekstur hasil ekstraksi GLCM digunakan sebagai masukan bagi model SVM untuk mengklasifikasikan citra X-ray ke dalam enam kategori patah tulang. Hasil evaluasi model ditunjukkan pada Tabel 9.

Tabel 12. Hasil Pengujian GLCM dan SVM

Metrik	Nilai
Accuracy	62,65%
Precision	66,26%
Recall	62,65%
F1-Score	62,65%


Berdasarkan hasil pengujian, kombinasi fitur GLCM dan algoritma SVM menghasilkan nilai

*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026

accuracy sebesar 62,65%, precision sebesar 66,26%, recall sebesar 62,65%, dan F1-score sebesar 62,65%. Hasil tersebut menunjukkan bahwa fitur tekstur yang diekstraksi menggunakan GLCM mampu memberikan informasi yang cukup baik untuk membedakan karakteristik patah tulang pada citra X-ray. Nilai precision yang lebih tinggi dibandingkan recall menunjukkan bahwa prediksi yang dihasilkan model cenderung memiliki tingkat ketepatan yang baik ketika suatu kelas berhasil dikenali.



Gambar 4. Confusion Matrix GLCM dan SVM

Berdasarkan confusion matrix pada Gambar 4, performa terbaik diperoleh pada kelas 4 dengan nilai F1-score sebesar 0,80. Sebaliknya, kelas 2 dan kelas 5 menunjukkan performa terendah dengan nilai F1-score sebesar 0,42. Sebagian besar data pada kelas 4 berhasil diklasifikasikan dengan benar, sedangkan kesalahan prediksi masih cukup sering terjadi pada kelas 2 dan kelas 5 yang diprediksi sebagai kelas lain. Hasil tersebut menunjukkan bahwa fitur GLCM telah mampu membedakan beberapa kategori patah tulang dengan baik, meskipun masih terdapat kelas yang memiliki karakteristik tekstur yang mirip.

3.7.2 Hasil GLCM dan ANN

Pengujian dilakukan menggunakan kombinasi fitur GLCM dan algoritma Artificial Neural Network (ANN). Pada tahap ini, fitur tekstur yang dihasilkan oleh metode GLCM digunakan sebagai masukan model ANN untuk mengklasifikasikan citra X-ray patah tulang ke dalam enam kategori kelas fracture.

Tabel 13. Hasil Pengujian GLCM dan ANN

Metrik	Nilai
--------	-------


*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026

Accuracy	65,06%
Precision	70,70%
Recall	65,06%
F1-Score	64,27%

Berdasarkan hasil pengujian pada Tabel 13, kombinasi metode ekstraksi fitur GLCM dan model ANN memperoleh nilai accuracy sebesar 65.06%, precision sebesar 70.70%, recall sebesar 65.06%, dan F1-score sebesar 64.27%. Hasil tersebut menunjukkan bahwa model ANN mampu mempelajari karakteristik tekstur global yang dihasilkan oleh metode GLCM dengan cukup baik sehingga memberikan performa klasifikasi yang lebih baik dibandingkan beberapa kombinasi metode lainnya.



Gambar 5. Confusion Matrix GLCM dan ANN

Berdasarkan confusion matrix GLCM dan ANN, kelas kedua memiliki jumlah prediksi benar tertinggi sebanyak 14 data, diikuti kelas kelima sebanyak 13 data. Sementara itu, kesalahan klasifikasi masih terlihat pada kelas ketiga yang beberapa datanya diprediksi sebagai kelas lain sehingga model masih mengalami kesulitan dalam membedakan beberapa kelas secara optimal. Hal ini menunjukkan bahwa model ANN mampu mengenali sebagian besar kategori fracture dengan cukup baik berdasarkan fitur GLCM.

3.7.3 Hasil GLCM dan BNN

Model Bayesian Neural Network (BNN) diuji menggunakan fitur hasil ekstraksi GLCM

*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026


yang telah melalui proses normalisasi dan persiapan data. Pengujian dilakukan untuk mengetahui kemampuan model dalam mengklasifikasikan citra X-ray patah tulang ke dalam enam kategori kelas berdasarkan karakteristik tekstur yang dihasilkan oleh metode GLCM.

Tabel 14. Hasil Pengujian GLCM dan BNN

Metrik	Nilai
Accuracy	21,69%
Precision	25,25%
Recall	21,69%
F1-Score	22,52%

Berdasarkan Tabel 14. model BNN yang menggunakan fitur GLCM memperoleh nilai accuracy sebesar 21,69%, precision sebesar 25,25%, recall sebesar 21,69%, dan F1-score sebesar 22,52%. Hasil tersebut menunjukkan bahwa performa model masih relatif rendah dalam mengklasifikasikan citra patah tulang berdasarkan fitur tekstur GLCM. Nilai F1-score yang diperoleh juga menunjukkan bahwa keseimbangan antara precision dan recall pada proses klasifikasi masih belum optimal.

Berdasarkan hasil classification report, performa terbaik diperoleh pada kelas Forearm Fracture dengan nilai F1-score sebesar 33%, diikuti oleh kelas Finger Positive dengan nilai F1-score sebesar 29%. Sementara itu, kelas Wrist Positive memperoleh nilai F1-score sebesar 0%, yang menunjukkan bahwa model belum mampu mengidentifikasi kelas tersebut dengan baik.



*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026

Gambar 6. Confusion Matrix GLCM dan BNN

Berdasarkan Gambar 6, nilai prediksi yang benar ditunjukkan oleh diagonal utama pada matriks konfusi. Namun, jumlah prediksi yang benar pada sebagian besar kelas masih relatif rendah dibandingkan jumlah data sebenarnya. Kelas Forearm Fracture menunjukkan performa terbaik dengan 4 prediksi benar dan nilai F1-score sebesar 33%, sedangkan kelas Wrist Positive tidak memiliki prediksi benar sama sekali sehingga menghasilkan nilai F1-score sebesar 0%. Selain itu, masih terdapat banyak kesalahan klasifikasi antar kelas, seperti pada kelas Finger Positive yang sebagian datanya diprediksi sebagai kelas lain. Hal ini menunjukkan bahwa model masih mengalami kesulitan dalam membedakan karakteristik tekstur antar kelas patah tulang berdasarkan fitur GLCM. Kondisi tersebut berdampak pada rendahnya nilai accuracy sebesar 21,69% dan F1-score sebesar 22,52% yang diperoleh model.

3.7.4 Hasil LBP dan SVM

Pengujian selanjutnya dilakukan menggunakan fitur Local Binary Pattern (LBP) dan algoritma Support Vector Machine (SVM). Pada tahap ini, fitur tekstur lokal hasil ekstraksi LBP digunakan sebagai masukan bagi model SVM untuk mengklasifikasikan citra X-ray patah tulang. Hasil evaluasi model ditunjukkan pada Tabel 15.

Tabel 15. Hasil Pengujian LBP dan SVM


Metrik	Nilai
Accuracy	57,83%
Precision	57,29%
Recall	57,83%
F1-Score	56,73%

Berdasarkan Tabel 15. model LBP dan SVM menghasilkan accuracy sebesar 57,83%, precision sebesar 57,29%, recall sebesar 57,83%, dan F1-score sebesar 56,73%. Nilai tersebut merupakan yang terendah dibandingkan kombinasi fitur lainnya pada model SVM. Hasil ini menunjukkan bahwa fitur LBP mampu merepresentasikan karakteristik tekstur lokal citra, namun informasi yang diperoleh belum cukup untuk membedakan seluruh kategori patah tulang secara optimal sehingga performa klasifikasi yang dihasilkan masih terbatas.

*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026



Gambar 7. Confusion Matrix LBP dan SVM

Berdasarkan confusion matrix pada Gambar 7, performa terbaik diperoleh pada kelas 4 dengan nilai F1-score sebesar 0,75, diikuti oleh kelas 3 dengan nilai F1-score sebesar 0,67. Sebaliknya, kelas 2 memiliki performa terendah dengan nilai F1-score sebesar 0,20 karena sebagian besar data pada kelas tersebut salah diklasifikasikan ke kelas lain. Hasil ini menunjukkan bahwa fitur LBP masih mengalami kesulitan dalam membedakan beberapa kategori patah tulang yang memiliki pola tekstur lokal yang serupa.

3.7.5 Hasil LBP dan ANN

Pengujian dilakukan menggunakan kombinasi fitur LBP dan algoritma ANN. Pada tahap ini, fitur tekstur lokal yang dihasilkan oleh metode LBP digunakan sebagai masukan model ANN untuk mengklasifikasikan citra X-ray patah tulang ke dalam enam kategori kelas fracture.

Tabel 16. Hasil Pengujian LBP dan ANN

Metrik	Nilai
Accuracy	51,81%
Precision	48,71%
Recall	51,81%
F1-Score	49,87%


Berdasarkan hasil pengujian pada Tabel 16. kombinasi metode ekstraksi fitur LBP dan model ANN memperoleh nilai accuracy sebesar 51.81%, precision sebesar 48.71%, recall

*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026

sebesar 51.81%, dan F1-score sebesar 49.87%. Hasil tersebut menunjukkan bahwa model ANN mampu melakukan klasifikasi citra X-ray menggunakan fitur tekstur lokal yang dihasilkan oleh metode LBP, meskipun performanya masih lebih rendah dibandingkan beberapa kombinasi model lainnya.



Gambar 8. Confusion Matrix LBP dan ANN

Berdasarkan confusion matrix LBP dan ANN, beberapa kelas fracture berhasil diprediksi dengan cukup baik terutama pada kelas kedua dan kelima yang memiliki jumlah prediksi benar paling tinggi. Namun, masih terdapat beberapa kesalahan klasifikasi pada beberapa kelas lain karena pola tekstur lokal antar citra memiliki kemiripan yang cukup tinggi sehingga model masih mengalami kesulitan dalam membedakan beberapa kelas fracture secara optimal.

3.7.6 Hasil LBP dan BNN

Model Bayesian Neural Network (BNN) diuji menggunakan fitur hasil ekstraksi Local Binary Pattern (LBP) yang telah melalui proses normalisasi dan persiapan data. Pengujian dilakukan untuk mengetahui kemampuan model dalam mengklasifikasikan citra X-ray patah tulang ke dalam enam kategori kelas berdasarkan karakteristik tekstur lokal yang dihasilkan oleh metode LBP.

Tabel 17. Hasil Pengujian LBP dan BNN

Metrik	Nilai
Accuracy	15,66%

*Corresponding author. Email: aut@foo.com or aut@foo2.com.


†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026

Precision	15,74%
Recall	15,66%
F1-Score	15,41%

Berdasarkan Tabel 17, model BNN yang menggunakan fitur LBP memperoleh nilai accuracy sebesar 15,66%, precision sebesar 15,74%, recall sebesar 15,66%, dan F1-score sebesar 15,41%. Hasil tersebut menunjukkan bahwa performa model masih rendah dalam mengklasifikasikan citra patah tulang berdasarkan fitur tekstur lokal yang dihasilkan oleh metode LBP. Nilai F1-score yang diperoleh juga menunjukkan bahwa keseimbangan antara precision dan recall pada proses klasifikasi masih belum optimal.

Berdasarkan hasil classification report, performa terbaik diperoleh pada kelas Forearm Fracture dengan nilai F1-score sebesar 32%. Sementara itu, kelas Elbow Positive dan Wrist Positive memperoleh nilai F1-score sebesar 0%, yang menunjukkan bahwa model belum mampu mengidentifikasi kedua kelas tersebut dengan baik.



Gambar 9. Confusion Matrix LBP dan BNN

Berdasarkan Gambar 9, jumlah prediksi yang benar pada diagonal utama masih relatif rendah dibandingkan jumlah data pada masing-masing kelas. Kelas Forearm Fracture menunjukkan performa terbaik dengan 5 prediksi benar dan nilai F1-score sebesar 32%, sedangkan kelas Elbow Positive dan Wrist Positive tidak memiliki prediksi benar sama sekali sehingga menghasilkan nilai F1-score sebesar 0%. Selain itu, masih terdapat banyak kesalahan klasifikasi antar kelas, misalnya pada kelas Shoulder Fracture yang sebagian besar datanya diprediksi sebagai kelas lain. Kondisi ini menunjukkan bahwa model masih mengalami kesulitan

*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026

dalam membedakan karakteristik tekstur lokal antar kelas patah tulang berdasarkan fitur LBP. Hal tersebut berdampak pada rendahnya nilai accuracy sebesar 15,66% dan F1-score sebesar 15,41% yang diperoleh model. Secara keseluruhan, hasil pengujian menunjukkan bahwa kombinasi fitur LBP dan model BNN belum mampu memberikan performa klasifikasi yang optimal pada dataset yang digunakan.

3.7.7 Hasil Fusion dan SVM

Pengujian berikutnya dilakukan menggunakan Feature Fusion yang merupakan penggabungan fitur GLCM dan LBP, kemudian diklasifikasikan menggunakan algoritma Support Vector Machine (SVM). Penggabungan fitur dilakukan untuk memanfaatkan informasi tekstur global dan tekstur lokal secara bersamaan sehingga diharapkan dapat meningkatkan performa klasifikasi. Hasil evaluasi model ditunjukkan pada Tabel 18.

Tabel 18. Hasil Pengujian Feature Fusion dan SVM


Metrik	Nilai
Accuracy	69,88%
Precision	70,76%
Recall	69,88%
F1-Score	69,18%

Berdasarkan Tabel 18, model Feature Fusion dan SVM memperoleh accuracy sebesar 69,88%, precision sebesar 70,76%, recall sebesar 69,88%, dan F1-score sebesar 69,18%. Nilai tersebut merupakan yang tertinggi dibandingkan penggunaan fitur GLCM maupun LBP secara terpisah. Hasil ini menunjukkan bahwa penggabungan kedua fitur mampu menghasilkan representasi tekstur yang lebih lengkap sehingga meningkatkan kemampuan model dalam membedakan kategori patah tulang.

*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026



Gambar 10. Confusion Matrix Feature Fusion dan SVM

Berdasarkan confusion matrix pada Gambar 10, performa terbaik diperoleh pada kelas 3 dan kelas 4 dengan nilai F1-score sebesar 0,83. Selain itu, kelas 0 juga menunjukkan performa yang baik dengan nilai F1-score sebesar 0,77. Sementara itu, kelas 2 masih menjadi kelas yang paling sulit dikenali dengan nilai F1-score sebesar 0,38 karena beberapa data masih diprediksi sebagai kelas lain. Secara keseluruhan, confusion matrix menunjukkan bahwa penggabungan fitur GLCM dan LBP mampu mengurangi kesalahan klasifikasi dibandingkan penggunaan fitur tunggal sehingga menghasilkan performa klasifikasi yang lebih baik.

3.7.8 Hasil Fusion dan ANN

Pengujian dilakukan menggunakan kombinasi feature fusion dan algoritma ANN. Pada tahap ini, fitur hasil penggabungan digunakan sebagai masukan model ANN untuk mengklasifikasikan citra X-ray patah tulang ke dalam enam kategori kelas fracture sehingga model dapat mempelajari karakteristik tekstur citra secara lebih lengkap.

Tabel 19. Hasil Pengujian Fusion dan ANN

Metrik	Nilai
Accuracy	72,29%
Precision	75,80%
Recall	72,29%


*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026

F1-Score	71,72%
----------	--------

Berdasarkan hasil pengujian pada Tabel 19. kombinasi feature fusion dan model ANN memperoleh nilai accuracy sebesar 72.29%, precision sebesar 75.80%, recall sebesar 72.29%, dan F1-score sebesar 71.72%. Hasil tersebut menunjukkan bahwa kombinasi feature fusion dan ANN mampu memberikan performa klasifikasi yang lebih baik dibandingkan penggunaan fitur tunggal karena informasi tekstur yang digunakan menjadi lebih lengkap.



Gambar 11. Confusion Matrix Feature Fusion dan ANN

Berdasarkan confusion matrix Fusion dan ANN, sebagian besar data berhasil diklasifikasikan dengan benar yang ditunjukkan oleh tingginya nilai pada diagonal utama matriks. Kelas kedua, keempat, dan kelima memiliki jumlah prediksi benar tertinggi masing-masing sebanyak 13 data, sedangkan kelas ketiga memiliki 12 prediksi benar. Hasil tersebut menunjukkan bahwa kombinasi Feature Fusion dan ANN mampu mengenali karakteristik fracture dengan lebih baik dibandingkan kombinasi metode lainnya. Namun, masih terdapat beberapa kesalahan klasifikasi pada beberapa kelas tertentu karena adanya kemiripan karakteristik tekstur antar citra fracture.

3.7.9 Hasil Fusion dan BNN

Model Bayesian Neural Network (BNN) diuji menggunakan fitur Feature Fusion yang merupakan gabungan dari fitur GLCM dan LBP. Pengujian dilakukan untuk mengetahui kemampuan model dalam mengklasifikasikan citra X-ray patah tulang berdasarkan kombinasi

*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.


Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026

fitur tekstur global dan lokal yang telah melalui proses normalisasi dan persiapan data.

Tabel 20. Hasil Pengujian Fusion dan BNN

Metrik	Nilai
Accuracy	21,69%
Precision	20,70%
Recall	21,69%
F1-Score	20,63%

Berdasarkan Tabel 20, model BNN yang menggunakan fitur Feature Fusion memperoleh nilai accuracy sebesar 21,69%, precision sebesar 20,70%, recall sebesar 21,69%, dan F1-score sebesar 20,63%. Hasil tersebut menunjukkan bahwa performa model masih relatif rendah dalam mengklasifikasikan citra patah tulang meskipun menggunakan kombinasi fitur GLCM dan LBP. Nilai F1-score yang diperoleh juga menunjukkan bahwa keseimbangan antara precision dan recall pada proses klasifikasi masih belum optimal. Berdasarkan hasil classification report, performa terbaik diperoleh pada kelas Shoulder Fracture dengan nilai F1-score sebesar 31%, diikuti oleh kelas Forearm Fracture dengan nilai F1-score sebesar 30%. Sementara itu, kelas Elbow Positive memperoleh nilai F1-score sebesar 0%, yang menunjukkan bahwa model belum mampu mengidentifikasi kelas tersebut dengan baik. Meskipun menggunakan fitur gabungan GLCM dan LBP yang menghasilkan representasi tekstur lebih lengkap, peningkatan jumlah fitur juga menyebabkan dimensi data menjadi lebih tinggi. Pada kondisi jumlah data yang relatif terbatas, model BNN belum mampu mengestimasi distribusi parameter secara optimal sehingga performa klasifikasi yang dihasilkan masih rendah dibandingkan model SVM dan ANN.



*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.


Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026

Gambar 12. Confusion Matrix Fusion dan BNN

Gambar 12, jumlah prediksi yang benar pada diagonal utama masih relatif rendah dibandingkan jumlah data pada masing-masing kelas. Kelas Shoulder Fracture menunjukkan performa terbaik dengan 5 prediksi benar dan nilai F1-score sebesar 31%, diikuti oleh kelas Forearm Fracture dengan nilai F1-score sebesar 30%. Sementara itu, kelas Elbow Positive tidak memiliki prediksi benar sama sekali sehingga menghasilkan nilai F1-score sebesar 0%. Selain itu, masih terdapat banyak kesalahan klasifikasi antar kelas, seperti pada kelas Finger Positive yang sebagian besar datanya diprediksi sebagai Wrist Positive. Hal ini menunjukkan bahwa model masih mengalami kesulitan dalam membedakan karakteristik tekstur antar kelas patah tulang meskipun menggunakan fitur gabungan GLCM dan LBP. Kondisi tersebut berdampak pada rendahnya nilai accuracy sebesar 21,69% dan F1-score sebesar 20,63% yang diperoleh model. Secara keseluruhan, hasil pengujian menunjukkan bahwa penggunaan Feature Fusion pada model BNN belum mampu memberikan peningkatan performa klasifikasi yang signifikan.

3.8 Visualisasi Sampel Hasil Prediksi Model Terbaik

Visualisasi dilakukan pada beberapa sampel data uji untuk menunjukkan kemampuan model terbaik dalam mengklasifikasikan citra X-ray patah tulang.



Gambar 13. Perbandingan Hasil Prediksi Menggunakan Model Terbaik pada Fitur GLCM, LBP,

*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026

dan Fusion

Berdasarkan Gambar 13, terlihat bahwa setiap metode ekstraksi fitur menghasilkan kemampuan klasifikasi yang berbeda pada sampel citra X-ray yang sama. Pada sampel pertama yang memiliki label sebenarnya *Forearm Fracture*, seluruh metode masih mengalami kesalahan klasifikasi dengan memprediksi citra sebagai *Elbow Positive*. Hal ini menunjukkan bahwa terdapat kemiripan pola tekstur antara kedua kelas tersebut sehingga model kesulitan membedakannya. Pada sampel kedua dengan label *Finger Positive*, ketiga metode juga memberikan prediksi *Wrist Positive*. Kesalahan ini mengindikasikan bahwa area tulang jari dan pergelangan tangan memiliki karakteristik tekstur yang relatif mirip setelah proses ekstraksi fitur.

Perbedaan performa mulai terlihat pada sampel ketiga dan keempat yang merupakan kelas *Humerus Fracture*. Pada sampel ketiga, metode GLCM dan Fusion berhasil memberikan prediksi yang sesuai dengan label sebenarnya, sedangkan metode LBP mengklasifikasikan citra sebagai *Forearm Fracture*. Pada sampel keempat, metode GLCM dan Fusion kembali menunjukkan prediksi yang benar sebagai *Humerus Fracture*, sementara LBP menghasilkan prediksi *Finger Positive*. Hasil ini menunjukkan bahwa fitur tekstur global yang ditangkap oleh GLCM lebih mampu merepresentasikan karakteristik patah tulang humerus dibandingkan fitur tekstur lokal yang digunakan oleh LBP.

Pada sampel kelima dengan label *Elbow Positive*, seluruh metode berhasil menghasilkan prediksi yang sesuai dengan kelas sebenarnya. Namun secara keseluruhan, metode Fusion menunjukkan performa yang paling stabil karena mampu mempertahankan hasil prediksi yang benar pada lebih banyak sampel dibandingkan metode lainnya. Penggabungan fitur GLCM dan LBP memungkinkan model memperoleh informasi tekstur global maupun lokal secara bersamaan sehingga representasi citra menjadi lebih lengkap. Temuan ini sejalan dengan hasil evaluasi kuantitatif yang menunjukkan bahwa kombinasi Fusion dan ANN menghasilkan akurasi tertinggi sebesar 72,29%, melampaui GLCM (65,06%) dan LBP (57,83%).

3.9 Perbandingan Performa Seluruh Model

Setelah dilakukan pengujian pada seluruh kombinasi fitur dan model klasifikasi, diperoleh hasil performa sebagaimana ditunjukkan pada Tabel 21 dan Gambar 15. Perbandingan dilakukan berdasarkan nilai accuracy, precision, recall, dan F1-score untuk mengetahui kombinasi metode yang memberikan hasil klasifikasi terbaik pada citra X-ray patah tulang.

Tabel 21. Perbandingan Performa Seluruh Model

Fitur	Model	Accuracy (%)	Precision (%)	Recall (%)	F1-Score (%)
GLCM	SVM	62,65	66,26	62,65	62,65
GLCM	ANN	65,06	70,70	65,06	64,27
GLCM	BNN	21,69	25,25	21,69	22,52
LBP	SVM	57,83	57,29	57,83	56,73


*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026

LBP	ANN	51,81	48,71	51,81	49,87
LBP	BNN	15,66	15,74	15,66	15,41
Fusion	SVM	69,88	70,77	69,88	69,18
Fusion	ANN	72,29	75,80	72,29	71,72
Fusion	BNN	21,69	20,70	21,69	20,63

Peningkatan performa pada metode Feature Fusion menunjukkan bahwa kombinasi informasi tekstur global dari GLCM dan tekstur lokal dari LBP mampu menghasilkan representasi citra yang lebih komprehensif dibandingkan penggunaan fitur tunggal. Hal ini memungkinkan model ANN mempelajari pola fracture secara lebih efektif sehingga menghasilkan nilai accuracy dan F1-score tertinggi.



Gambar 14. Perbandingan Accuracy Seluruh Model

Berdasarkan hasil pengujian, kombinasi Feature Fusion dan ANN menghasilkan performa terbaik dengan accuracy sebesar 72,29%, precision sebesar 75,80%, recall sebesar 72,29%, dan F1-score sebesar 71,72%. Hasil tersebut menunjukkan bahwa penggabungan fitur GLCM dan LBP mampu memberikan representasi tekstur yang lebih lengkap dibandingkan penggunaan satu jenis fitur saja sehingga meningkatkan kemampuan model dalam membedakan kategori patah tulang.

Sebaliknya, model BNN menunjukkan performa terendah pada seluruh jenis fitur dengan accuracy berkisar antara 15,66% hingga 21,69%. Sementara itu, model SVM dan ANN mampu memberikan hasil yang lebih baik, terutama ketika menggunakan fitur hasil Feature Fusion. Hasil tersebut menunjukkan bahwa penggunaan Feature Fusion secara konsisten menghasilkan performa yang lebih baik dibandingkan penggunaan fitur tunggal GLCM maupun LBP pada model SVM dan ANN. Secara keseluruhan, kombinasi Feature Fusion dan ANN dapat dianggap

*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026

sebagai metode terbaik pada penelitian ini karena menghasilkan nilai evaluasi tertinggi dibandingkan kombinasi metode lainnya.

3.10 Ringkasan Hasil Penelitian

Penelitian ini berhasil menerapkan metode ekstraksi fitur Gray Level Co-occurrence Matrix (GLCM), Local Binary Pattern (LBP), dan Feature Fusion pada klasifikasi citra X-ray patah tulang menggunakan model Support Vector Machine (SVM), Artificial Neural Network (ANN), dan Bayesian Neural Network (BNN). Sebelum proses klasifikasi dilakukan, dataset terlebih dahulu melalui tahap data cleaning dan preprocessing yang meliputi resize image, grayscale conversion, CLAHE enhancement, median blur, dan gaussian blur untuk meningkatkan kualitas citra serta mengurangi noise pada citra X-ray.

Berdasarkan hasil pengujian, penggunaan Feature Fusion memberikan performa yang lebih baik dibandingkan penggunaan fitur tunggal GLCM maupun LBP. Kombinasi Feature Fusion dan Artificial Neural Network (ANN) menghasilkan performa terbaik dengan accuracy sebesar 72,29%, precision sebesar 75,80%, recall sebesar 72,29%, dan F1-score sebesar 71,72%. Sementara itu, model Bayesian Neural Network (BNN) menunjukkan performa yang lebih rendah dibandingkan model SVM dan ANN pada seluruh jenis fitur yang digunakan. Secara keseluruhan, hasil penelitian menunjukkan bahwa penggabungan fitur tekstur mampu membantu model klasifikasi dalam mengenali karakteristik fracture pada citra X-ray secara lebih optimal.

4. Penutup

4.1 Kesimpulan

Berdasarkan hasil penelitian yang telah dilakukan, metode ekstraksi fitur Feature Fusion yang menggabungkan fitur Gray Level Co-occurrence Matrix (GLCM) dan Local Binary Pattern (LBP) mampu memberikan performa klasifikasi yang lebih baik dibandingkan penggunaan fitur tunggal pada citra X-ray patah tulang. Hasil pengujian menunjukkan bahwa kombinasi Feature Fusion dan Artificial Neural Network (ANN) menghasilkan performa terbaik dengan nilai accuracy sebesar 72,29%, precision 75,80%, recall 72,29%, dan F1-score 71,72%. Hasil tersebut menunjukkan bahwa penggabungan informasi tekstur global dan lokal mampu menghasilkan representasi fitur yang lebih lengkap sehingga meningkatkan kemampuan model dalam membedakan kategori patah tulang. Sementara itu, model Bayesian Neural Network (BNN) menunjukkan performa yang lebih rendah dibandingkan SVM dan ANN pada seluruh skenario pengujian yang dilakukan.

4.2 Saran

Penelitian selanjutnya disarankan untuk menggunakan dataset dengan jumlah data yang lebih besar dan distribusi kelas yang lebih seimbang guna meningkatkan kemampuan generalisasi model klasifikasi. Selain itu, pengembangan penelitian dapat dilakukan dengan

*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026

menerapkan metode ekstraksi fitur yang lebih kompleks atau pendekatan deep learning seperti Convolutional Neural Network (CNN), ResNet, maupun Vision Transformer (ViT) yang mampu mengekstraksi fitur secara otomatis dari citra X-ray. Penelitian berikutnya juga dapat mengeksplorasi teknik feature selection, hyperparameter tuning yang lebih optimal, serta penggunaan metode klasifikasi lain untuk memperoleh performa yang lebih tinggi dalam proses identifikasi patah tulang pada citra medis.

Ucapan Terima Kasih

Puji syukur kehadiran Allah SWT atas segala rahmat dan karunia-Nya sehingga laporan proyek yang berjudul *"Perbandingan Metode Ekstraksi Fitur Gray Level Co-occurrence Matrix (GLCM), Local Binary Pattern (LBP), dan Feature Fusion pada Klasifikasi Patah Tulang Citra X-ray Menggunakan Support Vector Machine (SVM), Artificial Neural Network (ANN), dan Bayesian Neural Network (BNN)"* dapat diselesaikan dengan baik.

Penulis mengucapkan terima kasih kepada Bapak Hasanuddin Al-Habib, S.Si., M.Si. dan Ibu Dr. Belgis Ainatul Iza, S.Si., M.Mat. selaku dosen pengampu yang telah memberikan bimbingan, arahan, dan masukan selama pelaksanaan proyek. Terima kasih juga kepada seluruh dosen Program Studi Sains Data, orang tua dan keluarga, rekan satu kelompok, serta semua pihak yang telah memberikan dukungan dan bantuan dalam penyusunan laporan ini. Penulis menyadari bahwa laporan ini masih memiliki keterbatasan, sehingga kritik dan saran yang membangun sangat diharapkan untuk perbaikan di masa mendatang. Semoga laporan ini dapat memberikan manfaat bagi pembaca dan menjadi referensi dalam pengembangan penelitian di bidang pengolahan citra digital.

Surabaya, Juni 2026

Kelompok 4

References

- Ahmed, K. D., & Hawezi, R. (2023). Detection of bone fracture based on machine learning techniques. *Measurement: Sensors*, 27, 100723. <https://doi.org/10.1016/j.measen.2023.100723>
- Alibabaei, S., Yousefipour, M., Rahmani, M., Raminfard, S., & Tahmasbi, M. (2025). Evaluating machine learning models for post-surgery treatment response assessment in glioblastoma multiforme: A comparative study of gray level co-occurrence matrix (GLCM), curvelet, and combined radiomics features selected by multiple algorithms. *BMC Medical Imaging*, 25(1). <https://doi.org/10.1186/s12880-025-01906-8>
- Alrais, R., & Elfadil, N. (2020). Support Vector Machine (SVM) for medical image

*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026

classification of tumorous. *International Journal of Computer Science and Mobile Computing*, 9(6), 37–45.

Ambika, M., & Mudda, M. (2020). Bone fracture detection using GLCM feature extraction. *International Journal of Scientific Research in Science, Engineering and Technology*, 8(7), 1370–1375.

J, U. (2018). Noise reduction in medical images using adaptive weighted median filter based on back propagation neural network. *International Journal of Advanced Research*, 6(9), 34–40. <https://doi.org/10.21474/IJAR01/7642>

Khaing Thinzar, S. M. (2019). Implementation of lower leg bone fracture detection from X-Ray images. *International Journal of Trend in Scientific Research and Development*, 3(5), 2411–2415.

Mall, P. K., Singh, P. K., & Yadav, D. (2019). GLCM based feature extraction and medical X-RAY image classification using machine learning techniques. In *Proceedings of the 2019 IEEE Conference on Information and Communication Technology (CICT)*. <https://doi.org/10.1109/CICT48419.2019.9066263>

Nia, S. N., & Shih, F. Y. (2024). Medical X-Ray image enhancement using global contrast-limited adaptive histogram equalization. *International Journal of Pattern Recognition and Artificial Intelligence*, 38(12). <https://doi.org/10.1142/S0218001424570106>

Oyeranmi, A., Ronke, B., Mohammed, R., & Edwin, A. (2020). Detection of fracture bones in X-ray images categorization. *Journal of Advances in Mathematics and Computer Science*, 35(4), 1–11. <https://doi.org/10.9734/JAMCS/2020/v35i430265>

Pradana, D., Alghifari, M. L., Juna, M. F., & Palaguna, D. (2022). Klasifikasi penyakit jantung menggunakan metode Artificial Neural Network. *Indonesian Journal of Data and Science*, 3(2), 55–60. <https://doi.org/10.56705/ijodas.v3i2.35>

4 Ujianto, N. T., Gunawan, Fadillah, H., Fanti, A. P., Saputra, A. D., & Ramadhan, I. G. (2025). Penerapan algoritma K-Nearest Neighbors (KNN) untuk klasifikasi citra medis. *IT-Explore: Jurnal Penerapan Teknologi Informasi dan Komunikasi*, 4(1), 33–43. <https://doi.org/10.24246/itexplore.v4i1.2025.pp33-43>

*Corresponding author. Email: aut@foo.com or aut@foo2.com.

†The journal does not allow footnote except the author information on the first page.

Received May 18, 2026; Revised May 18, 2026; Accepted May 18, 2026

Lampiran

<https://github.com/Cintyanareswari/Bone-Fracture-Classifications>